TP 3 : Data frames et dplyr

Introduction au langage R · Cnam · USSI6B-1

Consignes

Votre document.

- Téléchargez l'archive `tp3.zip` sur Moodle, décompressez-la et ouvrez le projet `tp3.Rproj`. Dans ce dossier, créez un document R Markdown nommé **`tp3_nom_prenom.Rmd`** (format HTML, table des matières), avec votre nom comme auteur.
- Son premier chunk, nommé `setup`, doit contenir `library(tidyverse)` puis `source("donnees_tp3.R")`. Ce fichier, fourni dans le dossier, crée les données du TP ; `airquality` et `msleep` sont déjà disponibles dans R.
- Structure imposée : un titre `#` par partie (`# Partie A…`) et un titre `##` par question, numéroté comme dans l'énoncé (`## A1`, `## A2`…).
- Pour chaque question : le code dans un ou plusieurs chunks, puis **une phrase de réponse** quand une question est posée.
- Les parties A et B se font **en R de base** (sans `dplyr`), les parties C et D **avec `dplyr`**.
- Le document doit se *knitter* sans erreur.

Rendu sur Moodle.

- Déposez **deux fichiers** : votre `.Rmd` et le `.html` knitté.
- Seul ce qui est déposé à la date limite (voir Moodle) est pris en compte.
- Vous pourrez être interrogé · e à l'oral sur votre code.

Partie A : Construire et interroger un data frame

Les vecteurs suivants sont créés par `donnees_tp3.R` :

```
prenom    <- c("Awa", "Bruno", "Chen", "Dina", "Elias",
               "Fatou", "Gaël", "Hugo", "Inès", "Jade")
age       <- c(24, 31, 22, 45, 28, NA, 35, 19, 27, 41)
filiere   <- c("info", "stat", "info", "eco", "stat",
               "eco", "info", "stat", "info", "eco")
note_r    <- c(14.5, 9, 17, 11.5, 12, 8.5, 15, NA, 16, 10)
note_stat <- c(12, 13.5, 15, 9, 14, 11, NA, 10.5, 17.5, 12.5)
```

A1. Créer le tableau

Créez le data frame `promo` à partir de ces vecteurs. La colonne `filiere` doit être un **facteur** dont les niveaux sont, dans cet ordre : `info`, `stat`, `eco`. Vérifiez la structure et les dimensions du tableau.

A2. Prédire avant d'exécuter

Pour chaque instruction ci-dessous, **prédisez par écrit** la classe et les dimensions (ou la longueur) du résultat, **avant** de l'exécuter. Exécutez-la ensuite, puis expliquez les différences.

```
promo[, 2]
promo[2]
promo[[2]]
promo[2, ]
promo[, c("age", "note_r")]
promo$ag
```

A3. Moyenne pondérée

Ajoutez une colonne `moyenne` : note de R coefficient 2, note de statistique coefficient 1, arrondie à 2 décimales. Combien d'étudiants n'ont pas de moyenne, et pourquoi ?

A4. Filtrer

Affichez le prénom, l'âge et la moyenne des étudiants de **25 ans ou plus** ayant **au moins 12** de moyenne. Aucune ligne `NA` ne doit apparaître.

A5. Trier

Triez le tableau par moyenne décroissante. Où apparaissent les étudiants sans moyenne ? Affichez ensuite le **podium** (prénom et moyenne).

A6. Résumés par filière

Donnez l'effectif de chaque filière, puis la moyenne de la colonne `moyenne` par filière (en ignorant les `NA`). Quelle filière a la meilleure moyenne ?

A7. Déboguer

Un camarade a écrit le code suivant. **Sans l'exécuter**, repérez l'erreur de chaque ligne et expliquez-la. Écrivez ensuite la version corrigée de chaque ligne et vérifiez-la.

```r
promo[promo$filiere = "info", ]          # 1. les étudiants en info
promo[promo$Age > 30]                    # 2. les plus de 30 ans
promo[promo$note_r > 15, "prenom"]       # 3. prénoms des plus de 15 en R
mean(promo$note_r)                       # 4. moyenne de R de la promo
sum(promo$filiere == "Info")             # 5. nombre d'étudiants en info
```

Partie B : Qualité de l'air à New York (R de base)

Le jeu `airquality` (intégré à R, voir `?airquality`) contient des mesures quotidiennes de mai à septembre 1973 : ozone (ppb), rayonnement solaire, vent (mph), température (°F), mois et jour. **Utilisez uniquement R de base dans cette partie.**

B1. Explorer

Combien de jours et de variables ? Combien de valeurs manquantes par variable ? Quel pourcentage de jours est **complet** (aucune variable manquante) ?

B2. Préparer le tableau

Créez `aq`, une copie d'`airquality`, avec deux colonnes supplémentaires :

- `TempC` : la température en degrés Celsius, arrondie à 1 décimale ;
- `Mois` : un facteur dont les étiquettes sont `mai`, `juin`, `juillet`, `août`, `septembre`.

B3. Les jours chauds

Combien de jours ont atteint **30 °C ou plus** ? Donnez leur répartition par mois. Quel est le mois le plus chaud en moyenne ?

B4. Pics d'ozone

Affichez le mois, le jour, l'ozone et la température (°C) des jours où l'ozone a dépassé **100 ppb**, triés par ozone décroissant. Aucune ligne `NA` ne doit apparaître.

B5. Ozone par mois

Construisez un data frame `ozone_mois` avec une ligne par mois et les colonnes `mois`, `n_mesures` (nombre de jours où l'ozone est mesuré), `moyenne`, `mediane` et `maximum`.

B6. Le jour le plus chaud de chaque mois

Affichez, pour chaque mois, le jour le plus chaud (mois, jour, température en °C). En cas d'égalité, gardez le premier jour du mois.

Indice : triez le tableau, puis regardez `?duplicated`.

B7. Ozone et chaleur

Comparez l'ozone moyen des jours à 30 °C ou plus et celui des autres jours. Dans quel rapport ? Peut-on conclure que la chaleur **cause** l'ozone ?

B8. Imputer les valeurs manquantes

On remplace chaque ozone manquant par la **médiane de son mois**. Créez la colonne `Ozone_imp`. Comparez la moyenne et l'écart-type de l'ozone avant et après imputation. Qu'en pensez-vous ?

Indice : un vecteur nommé (séance 2) peut servir de table de correspondance.

Partie C : Le sommeil des mammifères (dplyr)

Le jeu `msleep` (package `ggplot2`, chargé avec le tidyverse ; voir `?msleep`) décrit 83 espèces de mammifères. **Utilisez `dplyr` dans cette partie**, sauf mention contraire.

C1. Explorer

Utilisez `glimpse()`. Quelles variables ont **plus de 30 %** de valeurs manquantes ?

C2. Un tableau en français

Créez le tibble `ms` avec les colonnes `nom`, `regime`, `ordre`, `sommeil`, `sommeil_rem`, `cerveau` et `poids` (à partir de `name`, `vore`, `order`, `sleep_total`, `sleep_rem`, `brainwt` et `bodywt`). Recodez `regime` en français : `carnivore`, `herbivore`, `omnivore`, `insectivore` (les `NA` restent `NA`).

C3. Grands et petits dormeurs

Quelles espèces dorment **plus de 15 h** par jour ? Et **moins de 4 h** ? Triez chaque liste et indiquez le régime. Que remarquez-vous ?

C4. Nouvelles variables

Ajoutez à `ms` :

- `part_rem` : la part du sommeil paradoxal dans le sommeil total, en % ;
- `cerveau_pct` : le poids du cerveau en % du poids du corps ;
- `classe_poids` : un **facteur ordonné** à 4 niveaux, `< 1 kg`, `1-10 kg`, `10-100 kg` et `100 kg et plus`.

C5. Le sommeil selon le régime

Pour chaque régime (sans les `NA`), calculez le nombre d'espèces, le sommeil moyen, l'écart-type, le minimum et le maximum. Triez par sommeil moyen décroissant.

C6. Le sommeil selon la taille

Calculez le sommeil moyen et la part de sommeil paradoxal moyenne par classe de poids. Décrivez la tendance.

C7. Le champion de chaque régime

Pour chaque régime (sans les `NA`), affichez l'espèce qui dort le plus.

C8. Les ordres les mieux représentés

Pour les ordres comptant **au moins 5 espèces**, calculez le sommeil moyen et la médiane de `cerveau_pct`. Triez par sommeil moyen décroissant.

C9. Traduire en R de base

Réécrivez **en R de base** le calcul de la question C5 (nombre d'espèces et sommeil moyen par régime seulement). Vérifiez que vous obtenez les mêmes valeurs.

Partie D : Étude de cas sur les commandes d'une enseigne

Une enseigne de sport vend en **magasin**, sur **catalogue** et sur **internet**. Le fichier `data/commandes.csv` contient une ligne par **article commandé** entre 2003 et 2007. Il est importé par `donnees_tp3.R` :

```r
commandes <- read.csv("data/commandes.csv")
```

Variable	Contenu
`Customer_ID`	identifiant du client
`Employee_ID`	identifiant du vendeur ; `99999999` = vente sans vendeur
`Order_Date`, `Delivery_Date`	dates de commande et de livraison (`AAAA-MM-JJ`)
`Order_ID`	identifiant de la commande (une commande peut contenir plusieurs articles)
`Order_Type`	canal : 1 = magasin, 2 = catalogue, 3 = internet
`Product_ID`	identifiant du produit
`Quantity`	quantité
`Total_Retail_Price`	prix de vente **total** de la ligne (€)
`CostPrice_Per_Unit`	coût d'achat **unitaire** (€)

Utilisez `dplyr` dans cette partie.

D1. Premier contact

Combien de lignes ? Combien de **commandes**, de **clients** et de **produits** distincts ? Sur quelle période ?

Indice : `n_distinct()`.

D2. Nettoyer

Créez le tibble `cmd` :

- colonnes renommées en français : `client`, `vendeur`, `date_cmd`, `date_livr`, `commande`, `canal`, `produit`, `quantite`, `prix_total`, `cout_unitaire` ;
- `canal` : un facteur à étiquettes `magasin`, `catalogue`, `internet` ;
- `vendeur` : `NA` quand il vaut `99999999` ;
- `date_cmd` et `date_livr` converties en dates avec `as.Date()`.

D3. Variables calculées

Ajoutez à `cmd` :

- `cout_total` : le coût d'achat de la ligne ;
- `marge` : le prix de vente moins le coût ;
- `taux_marge` : la marge en % du prix de vente ;
- `delai` : le délai de livraison en jours (*indice : la différence de deux dates, convertie avec `as.numeric()`*) ;
- `annee` : l'année de la commande (*indice : `format(date, "%Y")`*).

D4. Comparer les canaux

Pour chaque canal : nombre de lignes, nombre de commandes distinctes, chiffre d'affaires (CA), marge totale, **taux de marge global** et délai moyen de livraison. Quel canal est le plus rentable ? Le plus rapide ?

D5. Évolution de la part d'internet

Calculez le CA par année et par canal, puis la **part de chaque canal dans le CA de l'année** (en %). Comment évolue la part d'internet ?

D6. Les meilleurs clients

Quels sont les 5 clients qui ont généré le plus de CA ? Pour chacun, donnez aussi le nombre de commandes et le canal le plus utilisé.

D7. Le panier moyen

Une commande peut contenir plusieurs articles. Calculez d'abord le **montant total de chaque commande**, puis le **panier moyen** et le nombre moyen d'articles par commande, pour chaque canal.

D8. Contrôle qualité

Y a-t-il des lignes avec un délai de livraison négatif ? Des lignes vendues **à perte** (marge négative) ? Si oui, combien, sur quels canaux, et pour quel montant de perte ?

D9. Synthèse

Rédigez, **sans chunk de code**, un paragraphe de 4 à 6 phrases destiné à la direction de l'enseigne. Il doit résumer les principaux enseignements des questions D4 à D8. Les chiffres clés doivent être insérés avec du **code R dans le texte** (`` `r ` ``), et non recopiés à la main.